

**PROIECTAREA UNUI DISPOZITIV DE RECUNOAȘTERE A
MIROSURILOR UTILIZÂND INTELIGENȚA ARTIFICIALĂ
(MACHINE LEARNIG)**

Palko Nandor – Robert

2025

1. Introducere

În zilele noastre, algoritmi de inteligență artificială sunt tot mai des întâlniți fie în domeniul ingineriei software, fie în domeniul ingineriei de sisteme autonome. Este un fenomen remarcabil faptul că, prin intermediul tehnologiei și al unor algoritmi software generali, se pot antrena agenți specifici pentru a îndeplini diferite îndatoriri. Astfel, este redus exponențial volumul de muncă pentru proiectarea fie a unui program software care să îndeplinească anumite sarcini, fie a unui sistem specific, în sensul că, prin intermediul metodelor clasice, orice sarcină avea o proiectare diferită.

Principalul avantaj al soluțiilor bazate pe inteligență artificială este structura generalizată a soluției unei probleme, mai exact, rezolvarea unei varietăți mari ale acestora sau îndeplinirea unui volum crescut de sarcini își are rădăcinile în două mari categorii ce funcționează unitar: o rețea neuronală și un algoritm specific de antrenare a acesteia.

În acest proiect se vor prezenta pașii de proiectare al unui sistem capabil de a diferenția diferite categorii de mirosuri prin utilizarea unor date specifice colectate pentru a observa diferențele exacte, respectiv prin antrenarea unei rețele neuronale pentru a fi capabilă de a lua decizii în acest sens.

2. Proiectare

2.1. Instrumente necesare

Pentru realizarea dispozitivului este nevoie de 2 elemente esențiale: un microcontroller sau microprocesor capabil de a rula algoritmi de inteligență artificială și senzori pentru colectarea datelor experimentale și funcționalitate finală.

Este de menționat că performanța unei rețele neuronale este direct proporțională cu numărul de date introduse pentru antrenament, timpul alocat antrenării și dimensiunea rețelei. Pentru acest proiect, este îndeajuns a se folosi un singur senzor de tip “Multichannel gas sensor” pentru detecția gazelor și a diverșilor compuși organice. Un astfel de senzor este capabil de a detecta o varietate de substanțe gazoase, cum ar fi:

- Monoxid de carbon (CO)
- Dioxid de azot (NO_2)
- Etanol
- Compuși organici volatili (VOC)




Figura 1. Multichannel gas sensor

Din punct de vedere al microcontroller-ului, se va folosi un Wio Terminal. Acesta dispune de un microcontroller încorporat de tip ATSAM, capabil de a suporta rularea unui program cu inteligență artificială, având o putere de calcul mai bună și o memorie FLASH mai mare decât microcontroller-ele întâlnite pe interfețele Arduino.



Figura 2. Wio Terminal

2.2. Colectarea datelor

Pentru a face posibilă crearea unei rețele neuronale și antrenarea acestuia, este esențială colectarea datelor destinate antrenării. De asemenea, folosind unele programe specializate de design al unor astfel de rețele, salvarea într-o anumită formă a datelor poate fi interpretată de aceste aplicații, fiind capabile de a stabili în mod automat variabilele de intrare și de ieșire ale rețelei neuronale.

Prin urmare, se va folosi o aplicație în mediul de programare ArduinoIDE de înregistrare a valorilor oferite de senzorul de gaz și aranjate în tabele de câte 10 linii (pentru un set de date) și 4 coloane (pentru fiecare set de date: CO, NO₂, VOC, Etanol). Cu ajutorul unui program realizat în Python, se vor salva aceste seturi de date de câte 10 linii și 4 coloane în fișiere de tip .csv, făcând posibilă citirea datelor de către rețeaua neuronală.

Acest proiect are ca scop detectarea a 4 tipuri de substanțe: aerul normal dintr-o încăpăre, cafea, ceai de fructe și ceai de mentă. Prin urmare, se va plasa senzorul de gaz în fiecare dintre aceste medii și se vor înregistra date timp de 10 minute. Se pot observa modificările valorilor de ieșire ale senzorului, factor esențial în posibilitatea, în primul rând, de a crea un astfel de dispozitiv.

Avantajul principal este că această analiză a diferențelor nu trebuie făcută de către programator, ci va fi realizată automat de către antrenamentul rețelei neuronale, scăzând exponențial timpul de lucru.

2.3.Proiectarea și antrenarea rețelei neuronale

Pentru pasul de proiectare și antrenare a rețelei neuronale se va folosi mediul de design și generare “Edge Impulse”. Astfel, se vor introduce datele experimentale colectate, urmată de declararea tipului de date de intrare și selectarea manuală a acestora, dacă este cazul. Tipul date de antrenament vor fi datele experimentale, prin urmare se va specifica în designer acest lucru.

În urma analizei datelor experimentale, s-a obținut următorul mediu de antrenament în care diferitele date de intrare sunt asociate cu mărimile de ieșire:




Figura 3. Mediul de antrenament pentru rețeaua neuronală

Următorul pas este adăugarea unui bloc de clasificare a mărimilor de intrare și a celor de ieșire pentru rețeaua neuronală. În acest caz, mărimile de intrare vor fi valorile efective ale monoxidului de carbon, dioxidului de azot, a compușilor organici și al etanolului, iar mărimile de ieșire vor reprezenta rezultatele oferite de rețea în urma analizei (Aer, Cafea, Ceai de fructe, Ceai de mentă)

În blocul de declarare a datelor se vor face ultimele modificări ale acestora, dacă este cazul, urmând ca în blocul de clasificare să se producă crearea rețelei neuronale propriu-zise. Se va declara primul strat al rețelei, având numărul de neuroni egal cu înmulțirea dintre numărul intrărilor cu cel al ieșirilor (în acest caz 16). Se vor declara 2 straturi intermediare astfel: primul cu 40 de neuroni, iar al 2-lea cu 20 de neuroni pentru o distribuție mai bună a datelor. Ultimul strat reprezintă numărul ieșirilor, în acest caz 4.

În urma a 300 de episoade de antrenament, s-au obținut următoarele rezultate:

Confusion matrix (validation set)

	AER	CAFEA	CEAIFRUCTE	CEAIMENTA
AER	100%	0%	0%	0%
CAFEA	0%	100%	0%	0%
CEAIFRUCTE	0%	0%	100%	0%
CEAIMENTA	0%	0%	0%	100%
F1 SCORE	1.00	1.00	1.00	1.00

Figura 4. Nivelul de acuratețe în diferențierea tipurilor de substanțe

Data explorer (full training set) ?




Figura 5. Reprezentare grafică a evoluției antrenamentului

Se poate observa faptul că rețeaua neuronală obținută, în urma antrenamentului, este capabilă să diferențieze cu o acuratețe de 100% cele 4 tipuri de substanțe dorite, raportat la colecția de date introdusă inițial.

Pentru o validare mai concisă, se va executa un test al rețelei pe un set de date nou generat de către aplicația Edge Impulse, urmărindu-se astfel performanțele acesteia. Se obțin astfel următoarele rezultate:

Confusion matrix

	AER	CAFEA	CEAIFRUCTE	CEAIMENTA	UNCERTAIN
AER	100%	0%	0%	0%	0%
CAFEA	0%	100%	0%	0%	0%
CEAIFRUCTE	0%	0%	100%	0%	0%
CEAIMENTA	0%	0%	0%	100%	0%
F1 SCORE	1.00	1.00	1.00	1.00	

Feature explorer ?




Figura 6. Validarea rezultatelor în urma testelor

Rețeaua neuronală se dovedește a fi corect antrenată, drept urmare se poate folosi pentru implementarea propriu-zisă a dispozitivului.

2.4. Implementarea fizică a dispozitivului

Aplicația Edge Impulse oferă posibilitatea generării unei librării ce conține rețeaua neuronală antrenată, adaptată pentru a se putea modela programul software în mediul de programare ArduinoIDE.

Principiul de bază al unui astfel de program constă în înregistrarea în timp real al valorilor analogice ale senzorului de gaz și trecerea acestor valori prin rețeaua neuronală. Scopul final este de a obține o ieșire corespunzătoare și dorită, afișată pe ecranul terminalului Wio, alături de un ” index de încredere”. Acest index reprezintă o valoare între 0 și 1, dată de unul dintre ieșirile rețelei neuronale, în funcție de valorile de intrare și de interpretare a acestora de către rețea. Se preia fiecare dintre cei 4 indecși și se stabilește maximul acestora, fiind considerat

rezultatul final al rețelei, urmând să fie afișat, alături de numele corespunzător indexului. Se obțin astfel următoarele rezultate:



Figura 7. Validare reală a indicatorului Aer




Figura 8. Validare reală a indicatorului Cafea




Figura 9. Validare reală a indicatorului Ceai
De Fructe




Figura 10. Validare reală a indicatorului Ceai
De Mentă

3. Concluzii

3.1. Observații

Se observă probleme în ceea ce privește natura senzorului și a substanțelor la care acesta este supus. Dacă senzorul este expus o perioadă îndelungată de timp asupra unei substanțe, acesta poate reține rămășițe ale aceluia mediu. Prin urmare, există riscul de a oferi informații eronate imediat după schimbarea mediului anterior cu cel curent, fiind necesar un timp de așteptare până când acesta să ofere informații corecte. Recomandarea este ca înainte de fiecare detecție, senzorul să fie poziționat într-un mediu neutru, cum ar fi aerul.

3.2. Îmbunătățiri

3.2.1. Gamă mai largă de date colecționate

Pentru proiectarea unui dispozitiv ce folosește inteligență artificială, este recomandată folosirea unei game largi de seturi de date. Astfel, rețeaua neuronală nu este mărginită de un set subțire de date din punct de vedere al diversității, favorizând astfel funcția decizională a rețelei. Prin urmare, pot contribui la setul de date o gamă mai largă de senzori pe lângă cei de gaz (temperatură, umiditate, presiune atmosferică, senzori de detecție a unei game mai largi de substanțe etc). De asemenea, este benefică înmulțirea aceluiași tip de senzor.

3.2.2. Înbunătățirea setului de date pentru antrenament

Expunerea îndelungată a senzorilor asupra mediului experimentat oferă un set de informații mai larg. Acest set favorizează antrenamentul rețelei, având la dispoziție o gamă mult mai largă de date destinate prelucrării și cizelării rețelei. De asemenea, este deosebit de benefică colectarea aceluiași tip de date în medii diferite (spre exemplu colectarea datelor referitoare la aer într-un mediu închis, într-un mediu deschis, la nivelul solului, la un nivel ridicat în altitudine, la diverse temperaturi etc.)

3.2.3. Îmbunătățirea rețelei neuronale și al antrenamentului

Creșterea numărului de straturi ale rețelei și al numărului de neuroni/strat favorizează categoric performanțele acesteia. De asemenea, un timp mai îndelungat al antrenamentului reduce nivelul de confuzie al rețelei, oferind în final performanțe mai bune în distingerea variabilelor introduse

4. Aplicații

- Industriale: Nevoia unui dispozitiv unitar de a distinge o gamă foarte largă de substanțe gazoase fără a fi nevoie de o varietate extinsă în ceea ce privește componentele fizice (mai mulți senzori individuali). Prin combinarea valorilor oferite de un număr mic de senzori capabili de a detecta substanțe măsurabile, se pot obține clasificări ale substanțelor nemăsurabile.
- Medicale: Principala temă a proiectului a constat în realizarea unui dispozitiv de recunoaștere a mirosurilor prin intermediul combinației de valori între mai multe substanțe prezente într-un compus. Prin urmare, în urma unei dezvoltări mai ample, este posibilă realizarea unui dispozitiv medical potrivit persoanelor cu dificultăți în ceea ce privește simțul olfactiv.